



DISRUPTIVE ARCHITECTURES: IOT, IOB & GENERATIVE IA

Enzo Ross Gallone – 551754 - 2TDSPM

Gabriel de Andrade Baltazar - 550870 – 2TDSPM

Leonardo Cordeiro Scotti – 550769 - 2TDSPM

Pedro Gomes Fernandes - 551480 - 2TDSPM

Vinícius de Araújo Camargo - 99494 - 2TDSPM

São Paulo, SP

2024

Documentação Completa do Projeto Atual: Previsão de Tendências no Mercado de Tecnologia

Resumo do Projeto

O projeto visa prever tendências de popularidade em tópicos relacionados a Inteligência Artificial (IA) e Machine Learning (ML) no mercado de tecnologia, utilizando uma rede neural LSTM (Long Short-Term Memory). A arquitetura LSTM foi escolhida por sua eficiência em lidar com dados temporais e sequenciais, o que possibilita a identificação de padrões de longo prazo em dados de séries temporais. Com um conjunto de dados de popularidade de IA e ML, o modelo foi treinado e validado para gerar previsões precisas, auxiliando na análise de tendências e insights de mercado.

Arquitetura LSTM

A arquitetura LSTM escolhida oferece as seguintes vantagens para o projeto:

- Unidades de Memória:** As unidades de memória da LSTM permitem reter informações importantes sobre o passado, útil para dados temporais.
- Portas de Controle:** A arquitetura utiliza portas de entrada, esquecimento e saída que controlam a quantidade de informação mantida ou descartada, evitando o problema do desvanecimento do gradiente e tornando-a eficiente em capturar dependências temporais longas.

Estrutura e Implementação do Modelo

O modelo foi estruturado em três camadas principais:

- Camadas LSTM:** Duas camadas LSTM sequenciais. A primeira retorna uma sequência completa, que é processada pela segunda camada para extrair características temporais importantes.
- Camada Densa:** Após as camadas LSTM, uma camada densa com uma unidade de saída é usada para gerar a previsão final, representando a popularidade projetada.

Treinamento e Avaliação do Modelo

Estrutura de Treinamento

- **Dados Escalados e Transformados:** Para garantir uma convergência eficiente do modelo, os dados foram normalizados para o intervalo [0, 1] com o MinMaxScaler.
- **Janelas Temporais:** Os dados de entrada foram organizados em janelas temporais, permitindo ao modelo aprender com múltiplas observações anteriores.
- **Configuração de Treinamento:** O modelo foi treinado usando o otimizador adam e a função de perda mean_squared_error, ideais para problemas de regressão.

Avaliação de Desempenho

Para avaliar o modelo em dados não vistos, o conjunto de dados foi dividido em treinamento e teste, e os seguintes indicadores foram utilizados:

- **Erro Quadrático Médio (MSE):** Para avaliar a média dos erros quadráticos das previsões.
- **R² Score:** Indica o quanto o modelo consegue explicar a variância dos dados de teste.
- **Erro Médio Absoluto (MAE):** Mede a média dos erros absolutos das previsões.
- **Erro Médio Percentual Absoluto (MAPE):** Indica a média do erro em relação ao valor real, em porcentagem.

Base de Dados

Estrutura do Conjunto de Dados

O conjunto de dados inclui métricas sobre a popularidade de tópicos em IA e ML, como popularidade, pesquisas crescentes e tendências de mercado.

Pré-processamento e Transformação

1. **Tratamento de Valores Ausentes:** Foi utilizado preenchimento com o valor mais recente, assegurando a consistência dos dados.

2. **Transformação de Variáveis:** Variáveis categóricas foram convertidas para o formato numérico (one-hot encoding) para facilitar a compreensão do modelo.
3. **Normalização:** Os dados foram normalizados para o intervalo [0, 1], o que ajudou a melhorar o desempenho do modelo.

Divisão dos Dados

Os dados foram divididos em um conjunto de treinamento e um de teste, garantindo que o modelo fosse validado em dados não vistos, proporcionando uma avaliação precisa do desempenho.

Visualização e Insights

A partir das previsões realizadas, foram geradas visualizações que ajudam a identificar picos e quedas de popularidade, destacando insights valiosos para o mercado:

1. **Correlação Entre Colunas:** Foi realizado um mapa de calor de correlação para identificar relações entre diferentes colunas e como essas relações influenciam a popularidade.
2. **Previsões e Valores Reais:** Um gráfico comparando as previsões do modelo com os dados reais, evidenciando a precisão das previsões.

Análise Final e Reflexão

A implementação da arquitetura LSTM mostrou-se adequada para o projeto, revelando-se eficiente na identificação de picos e quedas de popularidade no mercado de tecnologia. O modelo conseguiu capturar bem os padrões temporais dos dados, sugerindo que a abordagem baseada em LSTM foi bem-sucedida.

Pontos de Mudanças

Comparado ao projeto anterior:

1. **Visualização Detalhada:** Nesta versão, implementou-se um mapa de calor para visualizar as correlações entre variáveis, proporcionando insights adicionais.
2. **Criação de uma Coluna Combinada:** Uma nova coluna foi criada para analisar o impacto de variáveis combinadas na previsão de popularidade.

3. **Análise de Picos e Quedas:** Nesta versão, houve um foco maior na visualização dos pontos de pico e queda na popularidade, o que permitiu uma análise mais detalhada sobre o comportamento do mercado.

Conclusão

A LSTM é uma ferramenta poderosa para prever tendências em dados temporais. A inclusão de novas variáveis e a visualização de correlações foram diferenciais importantes que enriqueceram as análises, permitindo uma interpretação mais profunda dos resultados e ajudando a identificar padrões importantes.